


# Algoritmos Genéticos

Grado en Ingeniería Informática

Organización y Gestión de Empresas

José Manuel Galán  
Luis R. Izquierdo

Universidad de Burgos



## Estructura de la presentación

---

Aproximación evolutiva

Evolución artificial

Algoritmo genético



- Representación
- Inicialización
- Fitness
- Selección
- Cruce
- Mutación
- Reemplazamiento
- Criterio de parada

Algunos comentarios adicionales

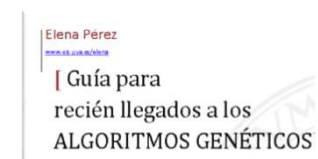
Resumen

# Bibliografía


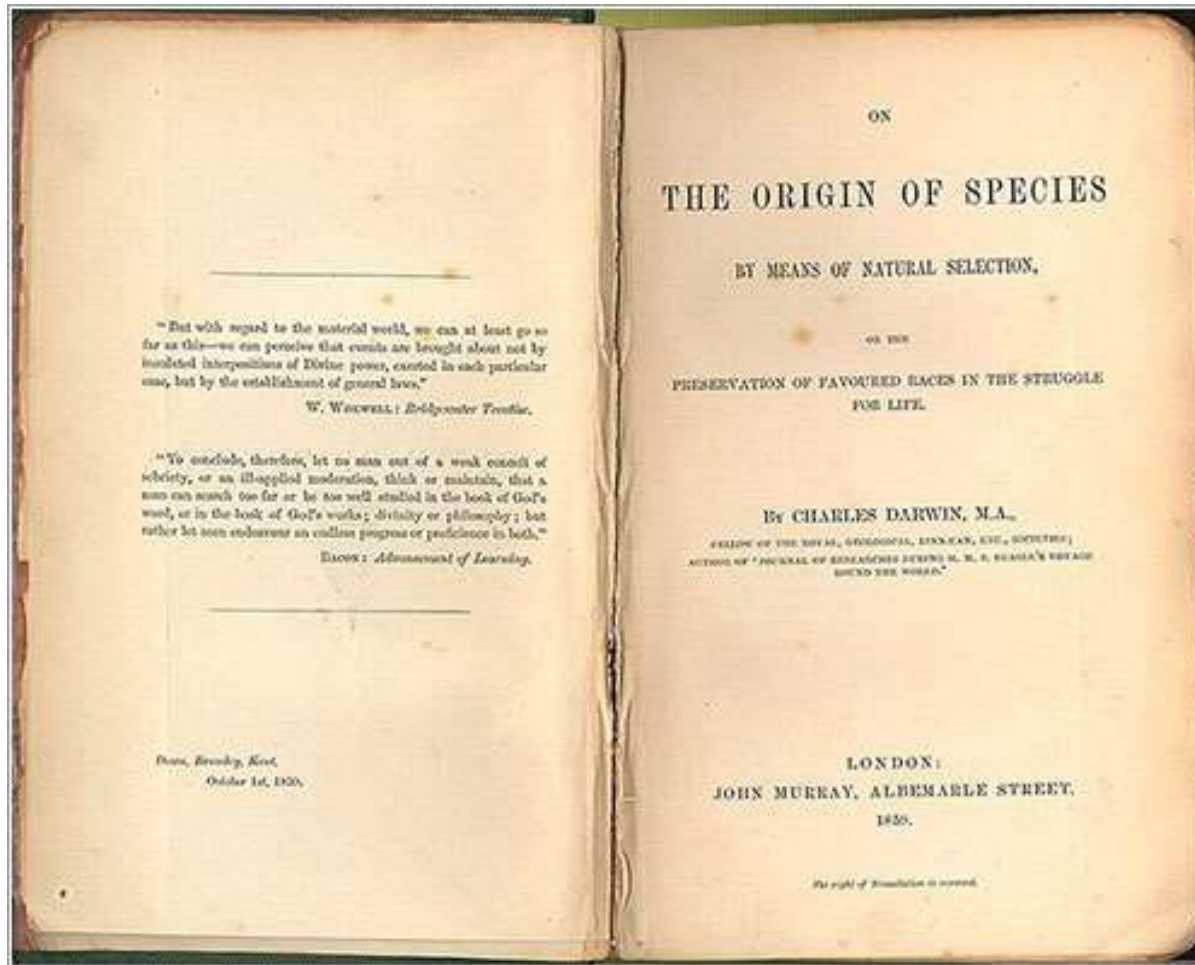
- Kenneth A. De Jong. Evolutionary Computation. A Unified Approach, (2006). MIT Press.
- Hillier, F.S., Lieberman, G.S. (2008) Introducción a la Investigación de Operaciones. McGraw-Hill. México D.F.
- D.E. Goldberg, Algoritmos Genéticos in Search, Optimization and Machine Learning. Addison Wesley, (1989)
- B. Melián, J.A. Moreno Pérez, J.M. Moreno Vega. Metaheurísticas: un visión global. Revista Iberoamericana de Inteligencia Artificial 19 (2003) 7-28
- Araujo, L., Cervigón, C. (2009) Algoritmos Evolutivos. Ra-Ma.
- Apuntes Algorítmica. Softcomputing and Soft Computing and Intelligent Information Systems. Universidad de Granada
- Luke, Sean (2014) Essentials of Metaheuristics. George Mason Univesity <https://cs.gmu.edu/~sean/book/metaheuristics/>
- Pérez, E. (2010) Guía para recién llegados a los Algorimos Genéticos. Universidad de Vallaoolid.



<http://sci2s.ugr.es/>



# Evolución natural



# Sistema evolutivo

- Diversidad: las entidades del sistema no son todas iguales; muestran diferencias que afectan a la llamada fitness individual.
- Selección: el mecanismo de selección es una fuerza discriminante que favorece a un conjunto específico de entidades en lugar de a otras
- Replicación / Herencia / Conservación: las propiedades de las entidades en el sistema (o las entidades en sí mismas) son conservadas, replicadas o heredadas de una generación a otra al menos en cierto grado

Richard Dawkins. (2006): *El gen egoísta* (3ª ed.). Oxford University Press.  
ISBN 0-1992-9114-4



# Biología evolutiva

- La evolución está centrada en los genes frente a las visiones centradas en los organismos vivos
- La selección natural es el vínculo entre los genes y la actuación (fitness) de sus estructuras decodificadas
- La reproducción es el punto en el que la evolución tiene lugar

# Biología evolutiva

- Creacionismo es la creencia religiosa de que el universo y la vida se originaron “a partir de actos específicos de creación divina”, en contraposición a la conclusión científica de que son consecuencia de procesos naturales
- El Lamarckismo (o herencia lamarckiana) es la idea de que un organismo puede pasar características adquiridas durante la vida a sus descendientes (también conocida como herencia de los rasgos adquiridos o herencia blanda)

# Algoritmo genético

- un conjunto prescrito de instrucciones o reglas bien definidas, ordenadas y finitas que permite llevar a cabo una actividad mediante pasos sucesivos
- En los 70, John Henry Holland en su libro *"Adaptation in Natural and Artificial Systems"* desarrolló una de las más prometedoras líneas de la inteligencia artificial: los algoritmos genéticos. Estos algoritmos se basan en la evolución biológica.
- *"Evolution as an engine for adaptation"*



Emergence: From Chaos to Order

John H. Holland. Redwood City, California: Addison-Wesley. 1998

Cloth: ISBN 0-201-14943-5







# Computación evolutiva

- Métodos basados en poblaciones en los que los individuos representan soluciones
- Algoritmos de optimización aleatoria que simulan un proceso evolutivo en un ordenador
- Con frecuencia proporcionan buenos resultados en problemas difíciles
- Hay diferentes aproximaciones: algoritmos genéticos, algoritmos meméticos, programación genética...

# Elementos básicos




## Idea intuitiva: el problema del viajante




(0)

## Idea intuitiva: el problema del viajante



(10)


## Idea intuitiva: el problema del viajante



(30)




## Idea intuitiva: el problema del viajante




(50)

## Idea intuitiva: el problema del viajante



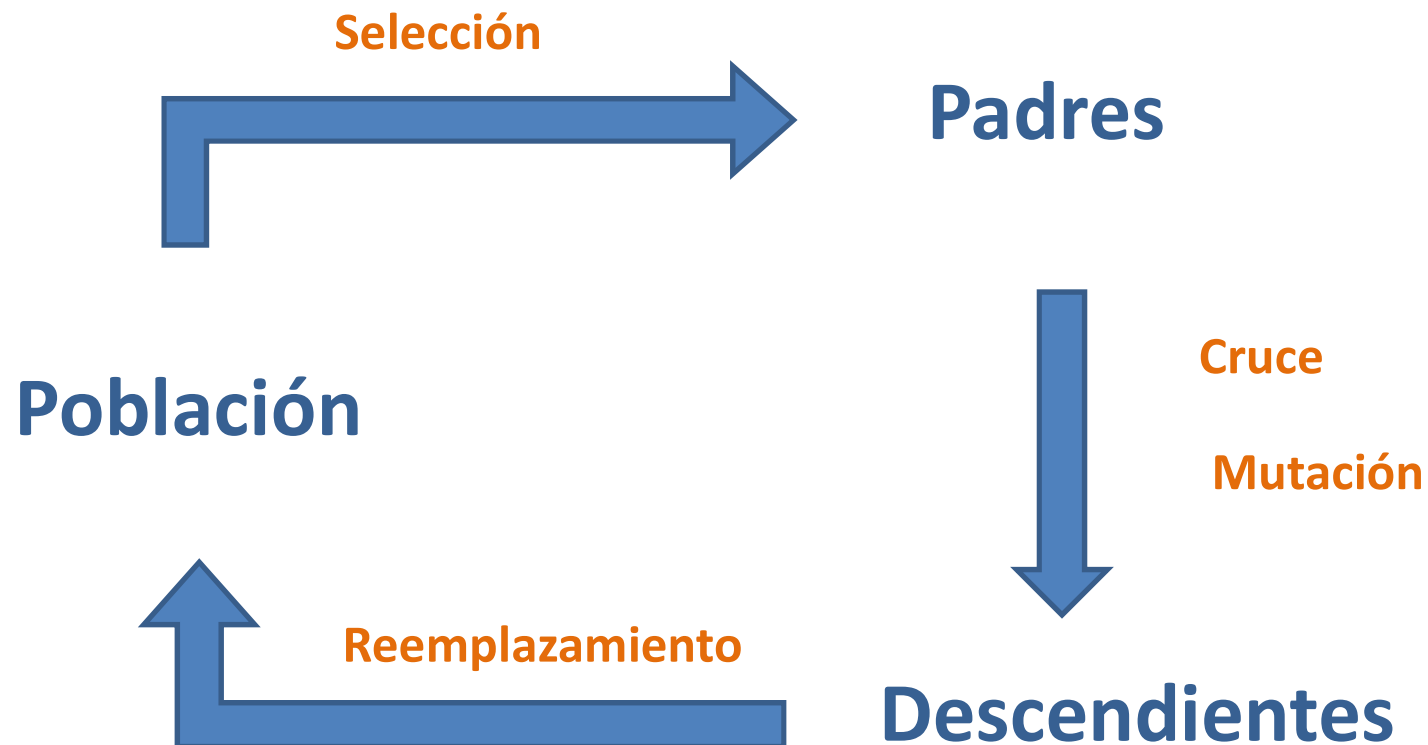
(70)

# Idea intuitiva: el problema del viajante





# Ciclo evolutivo



# Estructura del algoritmo

```
Begin (1)
  t=0
  Inicializar P(t)
  Evaluar P(t)
  While (criterio de parada) do
    Begin(2)
      t=t+1
      Selecciona P(t) from P(t-1)
      Recombinar P(t)
      Mutar P(t)
      Evaluar P(t)
    Final (2)
  Final (1)
```

# Pseudocódigo (algoritmo básico)

**Algorithm 20** *The Genetic Algorithm (GA)*

```
1:  $popsiz \leftarrow$  desired population size ▷ This is basically  $\lambda$ . Make it even.
2:  $P \leftarrow \{\}$ 
3: for  $popsiz$  times do
4:    $P \leftarrow P \cup \{\text{new random individual}\}$ 
5:  $Best \leftarrow \square$ 
6: repeat
7:   for each individual  $P_i \in P$  do
8:     AssessFitness( $P_i$ )
9:     if  $Best = \square$  or  $Fitness(P_i) > Fitness(Best)$  then
10:       $Best \leftarrow P_i$ 
11:    $Q \leftarrow \{\}$  ▷ Here's where we begin to deviate from  $(\mu, \lambda)$ 
12:   for  $popsiz/2$  times do
13:     Parent  $P_a \leftarrow \text{SelectWithReplacement}(P)$ 
14:     Parent  $P_b \leftarrow \text{SelectWithReplacement}(P)$ 
15:     Children  $C_a, C_b \leftarrow \text{Crossover}(\text{Copy}(P_a), \text{Copy}(P_b))$ 
16:      $Q \leftarrow Q \cup \{\text{Mutate}(C_a), \text{Mutate}(C_b)\}$ 
17:    $P \leftarrow Q$  ▷ End of deviation
18: until  $Best$  is the ideal solution or we have run out of time
19: return  $Best$ 
```

# Pasos para diseñar un algoritmo genético

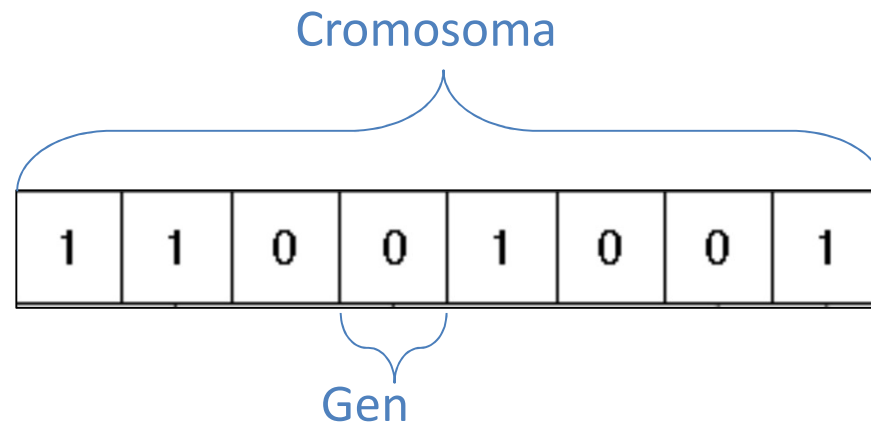
- Diseño de la representación
- Decidir como inicializar la población
- Diseñar la correspondencia entre genotipo y fenotipo
- Diseñar como evaluar la fitness de un individuo
- Diseñar el operador mutación adecuado
- Diseñar el operador de cruce apropiado
- Diseñar el mecanismo de selección
- Diseñar el proceso de reemplazamiento
- Definir la condición de parada

# Representación

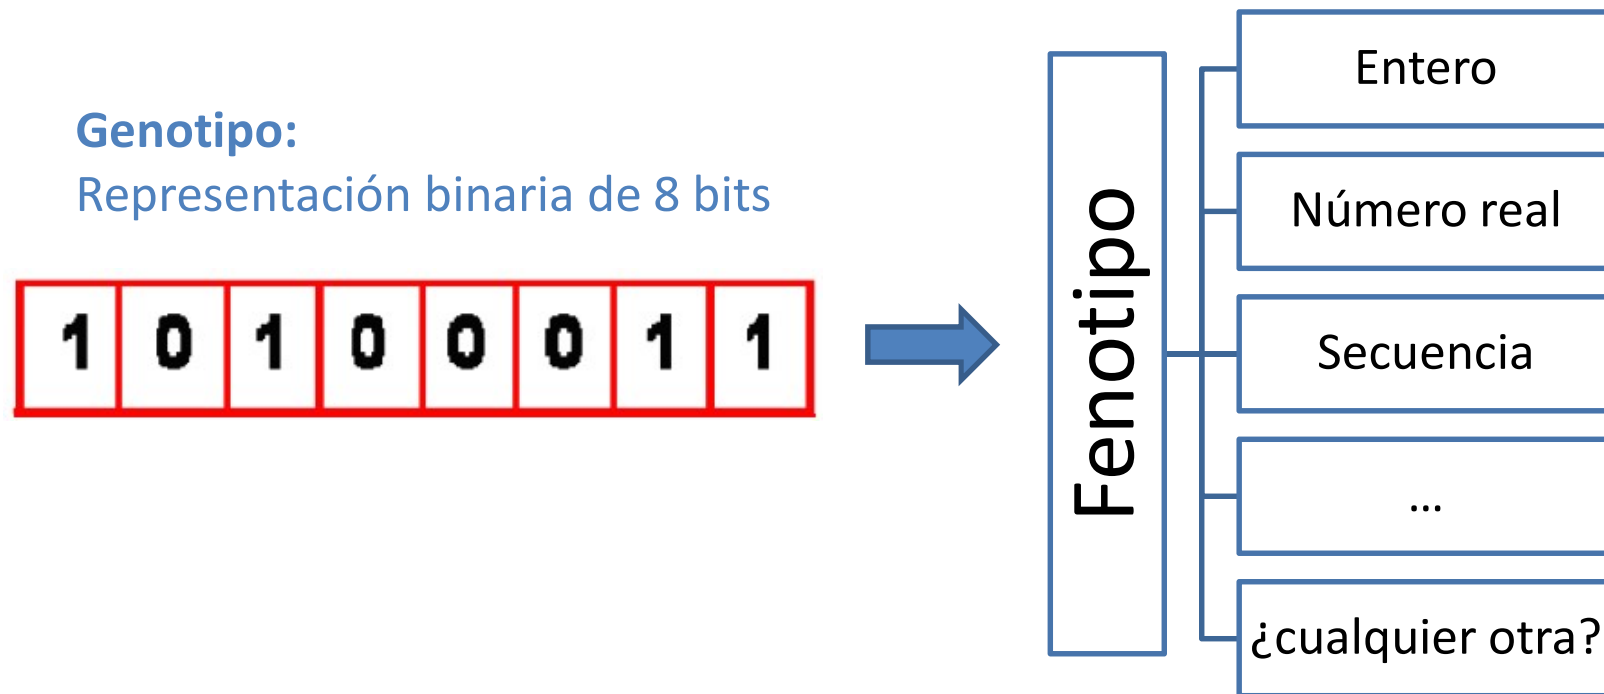
- Cada individuo (solución) debe representarse de acuerdo al problema a solucionar
- **Genotipo o genoma:** la estructura de datos de un individuo tal y como se utiliza durante el proceso de reproducción (cruce y mutación) (*breeding*)
- **Fenotipo:** como opera el individuo durante la evaluación de la fitness

# Codificación binaria

- **Cromosoma:** un genotipo en forma de un vector de longitud fija
- **Gen:** una posición particular en un cromosoma
- **Alelo:** un valor particular de un gen



# Codificación binaria



# Codificación binaria

**Genotipo:**

Representación binaria de 8 bits



**163**

**Fenotipo:**

Entero



$$1 \cdot 2^7 + 0 \cdot 2^6 + 1 \cdot 2^5 + 0 \cdot 2^4 + 0 \cdot 2^3 + 0 \cdot 2^2 + 1 \cdot 2^1 + 1 \cdot 2^0 =$$
$$128 + 32 + 2 + 1 = 163$$



# Codificación binaria

**Genotipo:**

Representación binaria de 8 bits



**Fenotipo:**

Número real entre 2.5 y 20.5



**13.9609**



$$x = 2.5 + \frac{163}{256} (20.5 - 2.5) = 13.9609$$

# Codificación real

- Otra forma de representación natural de muchos problemas es utilizar números reales como genes
- El cromosoma de los individuos viene representado como un vector fijo de números reales

$$X = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix}, x_i \in R$$

- Normalmente el fenotipo es un número real obtenido de una función de acuerdo a la siguiente forma:

$$f : R^n \rightarrow R$$

# Codificación permutacional o de orden

- Cuando una solución es una secuencia, una posible forma de ordenar algo, los individuos se representan mediante permutaciones

7	3	6	8	2	4	1	5
---	---	---	---	---	---	---	---

- Se utiliza esta representación en los problemas de scheduling
- El ejemplo más popular en el que se utiliza es en el problema del viajante, en el que a cada ciudad se asigna un único entero entre 1 y n
- Este tipo de codificación requiere operador especiales para garantizar que el resultado es también una permutación

# Inicialización

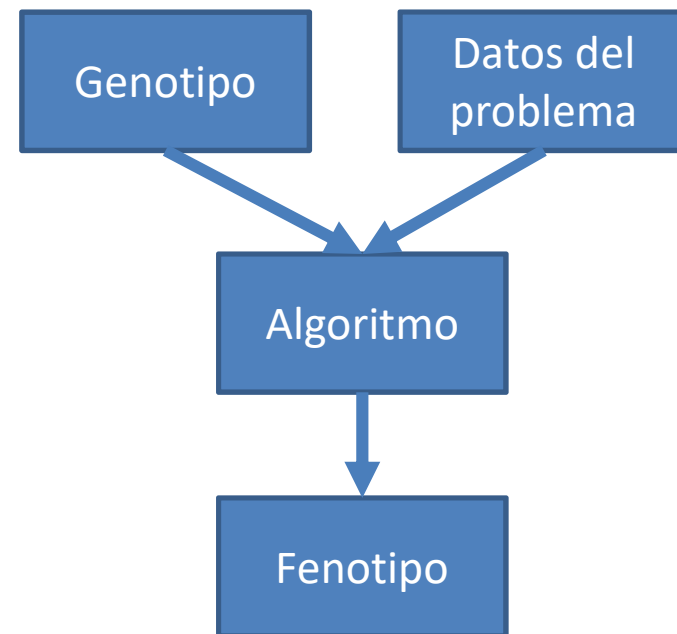
- Si es posible uniforme a lo largo de todo el espacio de soluciones
  - En el caso de codificación binaria: 0 ó 1 con probabilidad 0.5 para cada gen
  - Con codificación real: uniforme en los diferentes intervalos
- Soluciones optimizadas de heurísticas previas no suele ser una buena idea

# Evaluación de la función de fitness

- **Fitness:** calidad de la solución
- **Fitness landscape:** función objetivo
- Normalmente es el paso más costoso computacionalmente en aplicaciones reales
- Puede ser una subrutina, un simulador o cualquier proceso externo (e.g. experimentos con robots,...)
- En algunas situaciones se utilizan funciones aproximadas para tratar de reducir el coste computacional
- En caso de restricciones, se pueden integrar como coste adicional en la función de fitness
- Se pueden utilizar funciones multiobjetivo

# Correspondencia entre genotipo y fenotipo

- En algunos caso el proceso es simple
- Pero en otros, el genotipo puede ser un conjunto de parámetros de otro algoritmo o una simulación que debe ser ejecutada para obtener el fenotipo

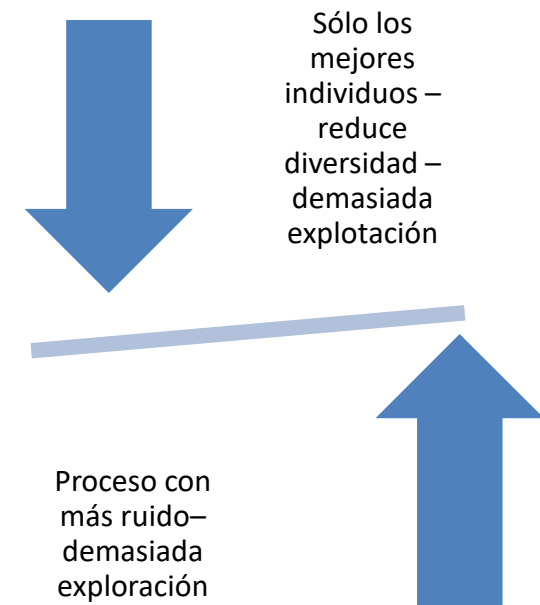


# Ciclo evolutivo. Diseño de un algoritmo genético(I)



# Estrategia de selección


- **Selección:** elección de los individuos basada en la fitness
- Los mejores individuos deben tener una probabilidad mayor de ser elegidos como padres
- Pero los individuos no tan buenos deben tener también opción de reproducirse. Es posible que incluyan material genético útil
- Esta idea define **la presión de selección** del proceso, el grado en el que la reproducción es dirigida por los mejores individuos





# Mecanismos de selección populares


- **Torneo aleatorio (Random tournament)**



Source: Galan, J. M. & Izquierdo, L. R. (2005). Appearances Can Be Deceiving: Lessons Learned Re-Implementing Axelrod's 'Evolutionary Approach to Norms'. Journal of Artificial Societies and Social Simulation 8(3)2.  
<http://jasss.soc.surrey.ac.uk/8/3/2.html>

# Mecanismos de selección populares


- **Selección por ruleta (Roulette wheel)**



# Mecanismos de selección populares

- **Selección media  
(Average  
selection)**

Para mantener la población constante es mejor utilizar la mediana en lugar de la media



Source: Galan, J. M. & Izquierdo, L. R. (2005). Appearances Can Be Deceiving: Lessons Learned Re-Implementing Axelrod's 'Evolutionary Approach to Norms'. Journal of Artificial Societies and Social Simulation 8(3)2.  
<http://jasss.soc.surrey.ac.uk/8/3/2.html>

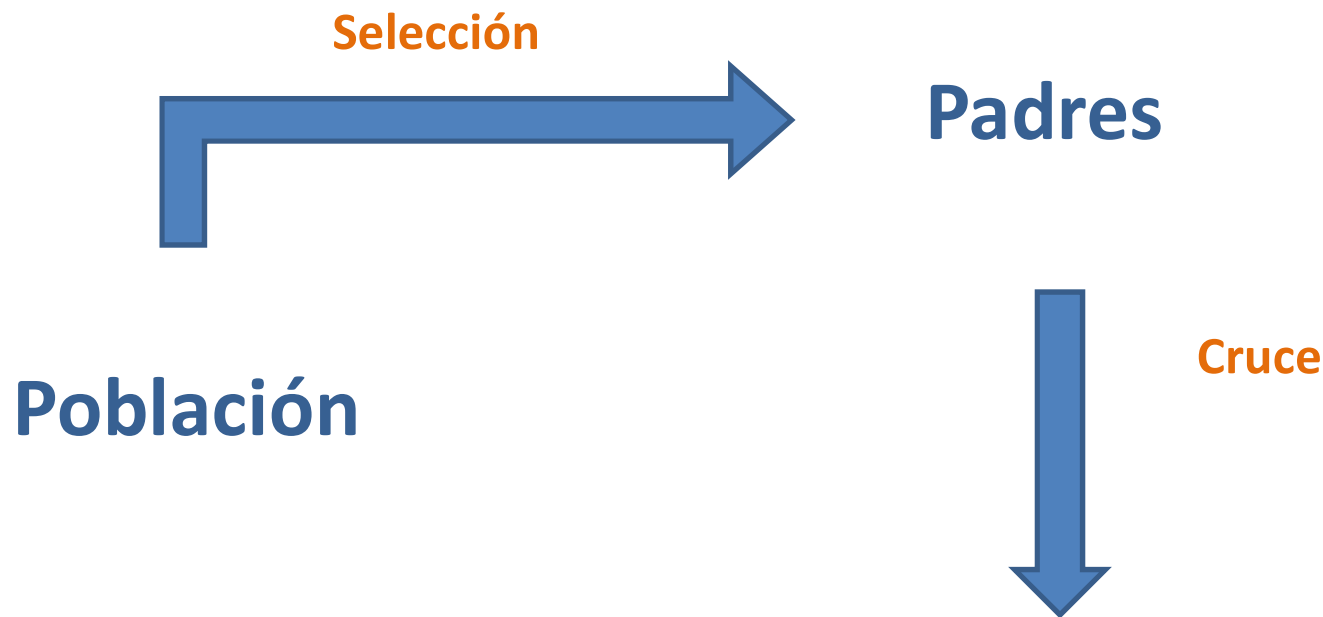
# Mecanismos de selección populares

- Otros métodos de truncamiento



Source: Galan, J. M. & Izquierdo, L. R. (2005). Appearances Can Be Deceiving: Lessons Learned Re-Implementing Axelrod's 'Evolutionary Approach to Norms'. Journal of Artificial Societies and Social Simulation 8(3)2.  
<http://jasss.soc.surrey.ac.uk/8/3/2.html>

# Ciclo evolutivo. Diseño de un algoritmo genético(II)



# Operador cruce

- **Recombinación o cruce:** un sistema especial de modificación de soluciones que normalmente conlleva elegir dos padres, intercambiar secciones de ambos y (normalmente) producir dos hijos. Normalmente se considera un sistema de reproducción “sexual”.
- Se pueden utilizar diferentes operadores cruce en el mismo algoritmo
- Aspectos relevantes:
  - Los hijos deben heredar características de cada padre
  - Es dependiente de la representación del genotipo
  - La recombinación debe producir cromosomas válidos
  - Normalmente se utiliza asociado a una cierta probabilidad ( $P_c$  entre 0.6 y 0.9). No todos los padres son recombinados ya que el operador cruce puede ser destructivo

# Cruce para codificación binaria

- Cruce en un punto

### Algorithm 23 One-Point Crossover

- 1:  $\vec{v} \leftarrow$  first vector  $\langle v_1, v_2, \dots, v_l \rangle$  to be crossed over
- 2:  $\vec{w} \leftarrow$  second vector  $\langle w_1, w_2, \dots, w_l \rangle$  to be crossed over
- 3:  $c \leftarrow$  random integer chosen uniformly from 1 to  $l$  inclusive
- 4: **if**  $c \neq 1$  **then**
- 5:     **for**  $i$  from 1 to  $c - 1$  **do**
- 6:         Swap the values of  $v_i$  and  $w_i$
- 7: **return**  $\vec{v}$  and  $\vec{w}$




Figure 9 One-Point Crossover.

# Cruce para codificación binaria

- Cruce en dos puntos

## Algorithm 24 Two-Point Crossover

- 1:  $\vec{v} \leftarrow$  first vector  $\langle v_1, v_2, \dots, v_l \rangle$  to be crossed over
- 2:  $\vec{w} \leftarrow$  second vector  $\langle w_1, w_2, \dots, w_l \rangle$  to be crossed over
- 3:  $c \leftarrow$  random integer chosen uniformly from 1 to  $l$  inclusive
- 4:  $d \leftarrow$  random integer chosen uniformly from 1 to  $l$  inclusive
- 5: **if**  $c > d$  **then**
- 6:     Swap  $c$  and  $d$
- 7: **if**  $c \neq d$  **then**
- 8:     **for**  $i$  from  $c$  to  $d - 1$  **do**
- 9:         Swap the values of  $v_i$  and  $w_i$
- 10: **return**  $\vec{v}$  and  $\vec{w}$




Figure 10 Two-Point Crossover.

<sup>24</sup>We can generalize two-point crossover into a **Multi-Point Crossover**: pick  $n$  random points and sort them smallest first:  $c_1, c_2, \dots, c_n$ . Now swap indexes in the region between  $c_1$  and  $c_2$ , and between  $c_3$  and  $c_4$ , and likewise  $c_5$  and  $c_6$ , etc.



# Cruce para codificación binaria

- Cruce uniforme




Figure 11 Uniform Crossover.


## Algorithm 25 Uniform Crossover

- 1:  $p \leftarrow$  probability of swapping an index ▷ Often  $p$  is set to  $1/l$ . At any rate,  $p \leq 0.5$
- 2:  $\vec{v} \leftarrow$  first vector  $\langle v_1, v_2, \dots, v_l \rangle$  to be crossed over
- 3:  $\vec{w} \leftarrow$  second vector  $\langle w_1, w_2, \dots, w_l \rangle$  to be crossed over
- 4: **for**  $i$  from 1 to  $l$  **do**
- 5:     **if**  $p \geq$  random number chosen uniformly from 0.0 to 1.0 inclusive **then**
- 6:         Swap the values of  $v_i$  and  $w_i$
- 7: **return**  $\vec{v}$  and  $\vec{w}$

<sup>25</sup>The original uniform crossover assumed  $p = 1/2$ , and was first proposed in David Ackley, 1987, *A Connectionist Machine for Genetic Hillclimbing*, Kluwer Academic Publishers. The more general form, for arbitrary  $p$ , is sometimes called *parameterized* uniform crossover.

# Cruce para codificación real

- **Cruce uniforme**




### Algorithm 25 *Uniform Crossover*

- 1:  $p \leftarrow$  probability of swapping an index ▷ Often  $p$  is set to  $1/l$ . At any rate,  $p \leq 0.5$
- 2:  $\vec{v} \leftarrow$  first vector  $\langle v_1, v_2, \dots, v_l \rangle$  to be crossed over
- 3:  $\vec{w} \leftarrow$  second vector  $\langle w_1, w_2, \dots, w_l \rangle$  to be crossed over
- 4: **for**  $i$  from 1 to  $l$  **do**
- 5:     **if**  $p \geq$  random number chosen uniformly from 0.0 to 1.0 inclusive **then**
- 6:         Swap the values of  $v_i$  and  $w_i$
- 7: **return**  $\vec{v}$  and  $\vec{w}$

# Cruce para codificación real

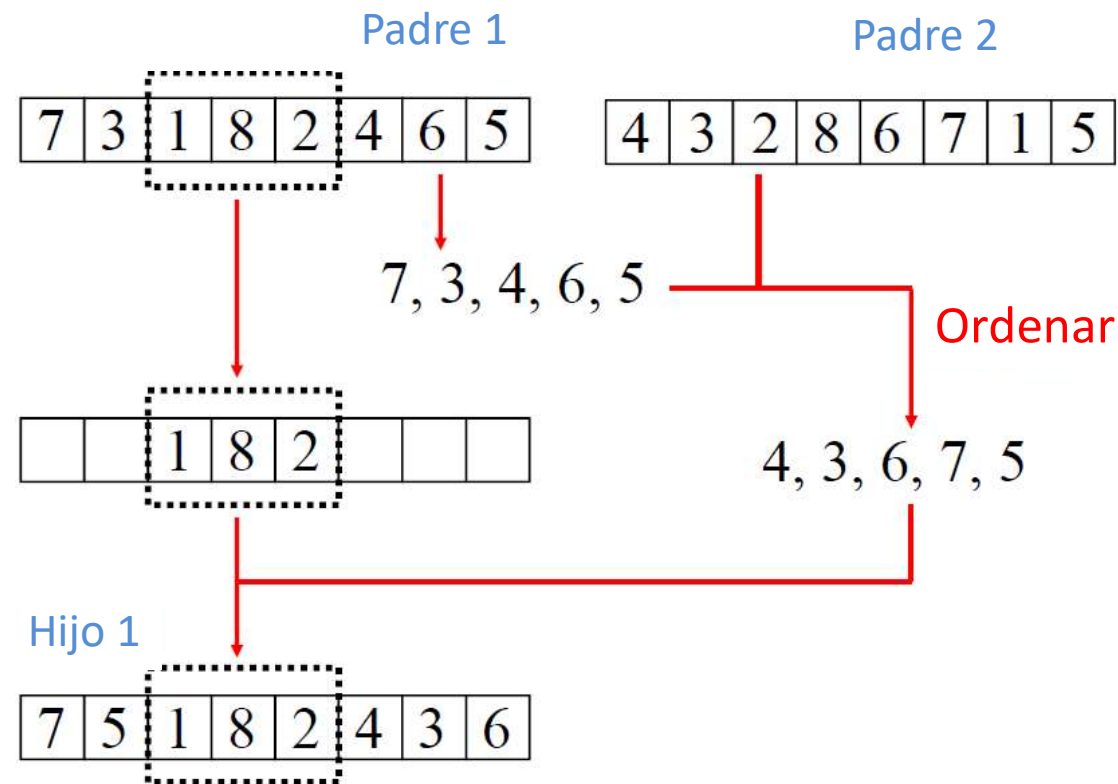
- **Cruce aritmético**



Hay muchísimas opciones para cruce real

# Cruce para representación permutacional

- **Cruce OX (order)**



# Cruce para representación permutacional

- **Cruce PMX (partially matched)**
  - Selecciona aleatoriamente un segmento central y establece una correspondencia entre los genes de cada padre
  - Cada hijo contiene el elemento central de uno de los padres y el máximo número de posiciones correspondientes al otro padre. Si no es posible la asignación, se realiza a partir de la correspondencia

Padre 1 = (1 2 3 | 4 5 6 7 | 8 9)

Padre 2 = (4 5 3 | 1 8 7 6 | 9 2)

Hijo' 1 = (\* \* \* | 1 8 7 6 | \* \*)

Hijo' 2 = (\* \* \* | 4 5 6 7 | \* \*)

**Correspondencia** : (1-4, 8-5, 7-6, 6-7)

Hijo 1 = (1-4 2 3 | 1 8 7 6 | 8-5 9) = (4 2 3 | 1 8 7 6 | 5 9)

Hijo 2 = (4-1 5-8 3 | 4 5 6 7 | 9 2) = (1 8 3 | 4 5 6 7 | 9 2)

# Cruce para representación permutacional

- **Cruce CX (cycle)**

- Elige aleatoriamente una posición y sigue las restricciones creadas hasta que encuentres un ciclo
- Repite el proceso hasta generar un hijo

Padre 1 = (1 2 3 4 5 6 7 8)

Padre 2 = (2 4 6 8 7 5 3 1)

Elija aleatoriamente entre 1 y 2 (la primera posición de ambos vectores). Imagine que sale 1

(1 \* \* \* \* \* \*) → (1 \* \* \* \* \* 8) → (1 \* \* 4 \* \* \* 8) → (1 2 \* 4 \* \* \* 8)

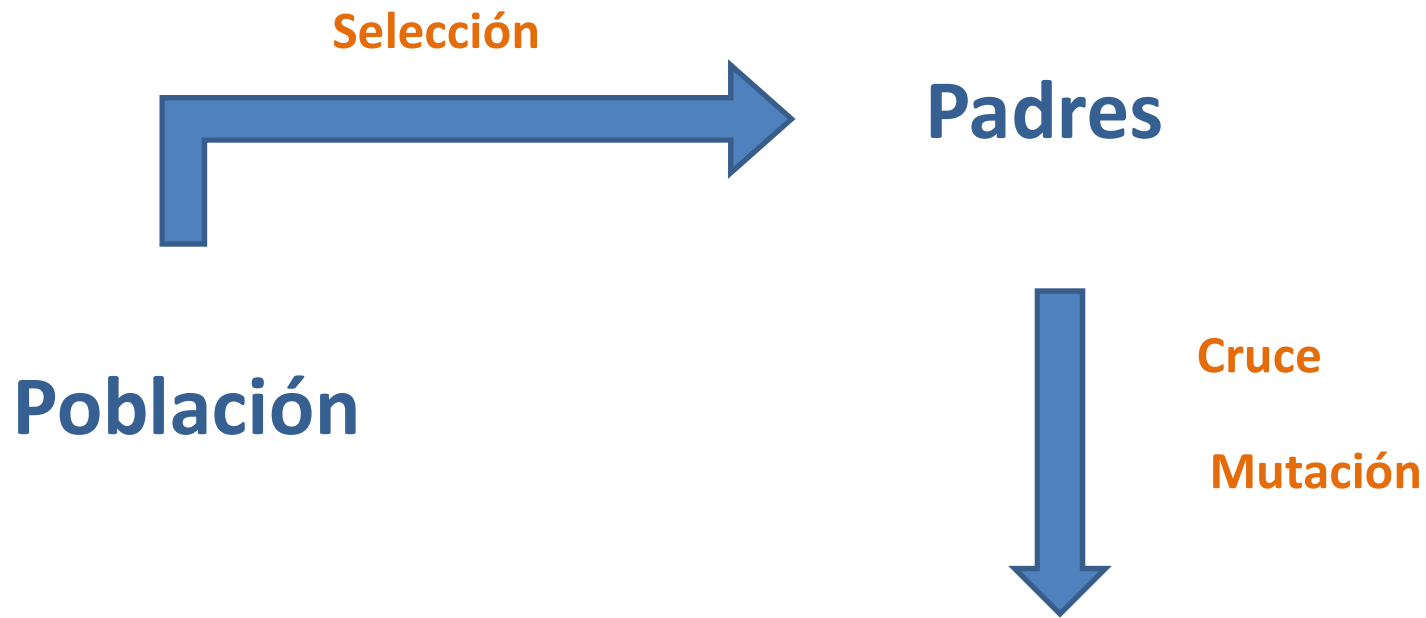
Se ha encontrado un ciclo.

Elija aleatoriamente entre 3 y 6 (la primera posición libre de ambos vectores). Imagine un 6

Hijo = (1 2 6 4 \* \* \* 8)

Hijo = (1 2 6 4 7 5 3 8)

# Ciclo evolutivo. Diseño de un algoritmo genético(III)



# Operador mutación

- **Mutación:** modificación. A veces se considera reproducción “asexual”
- Se pueden utilizar diferentes operadores en el mismo algoritmo
- Aspectos relevantes
  - Cualquier punto del espacio de búsqueda debería poder ser alcanzado
  - La cantidad de mutación se debe controlar
  - La mutación debe producir cromosomas válidos
  - Se debe utilizar como una pequeña probabilidad para cada nuevo hijo tras el operador cruce (incluyendo también los padres no recombinados)



# Mutación para codificación binaria

- Probabilidad  $P_m$  para cada gen

Antes de la  
mutación

1	1	1	1	1	1	1	1
---	---	---	---	---	---	---	---



Después de  
la mutación

1	1	1	0	1	1	1	1
---	---	---	---	---	---	---	---

# Mutación para codificación real

- Perturbación aleatoria
- Normalmente mediante ruido blanco  $N(0, \sigma)$ 
  - 0 es la media
  - $\sigma$  es la desviación estándar
  - $x'_i = x_i + N(0, \sigma_i)$  para cada parámetro

# Mutación para codificación permutacional

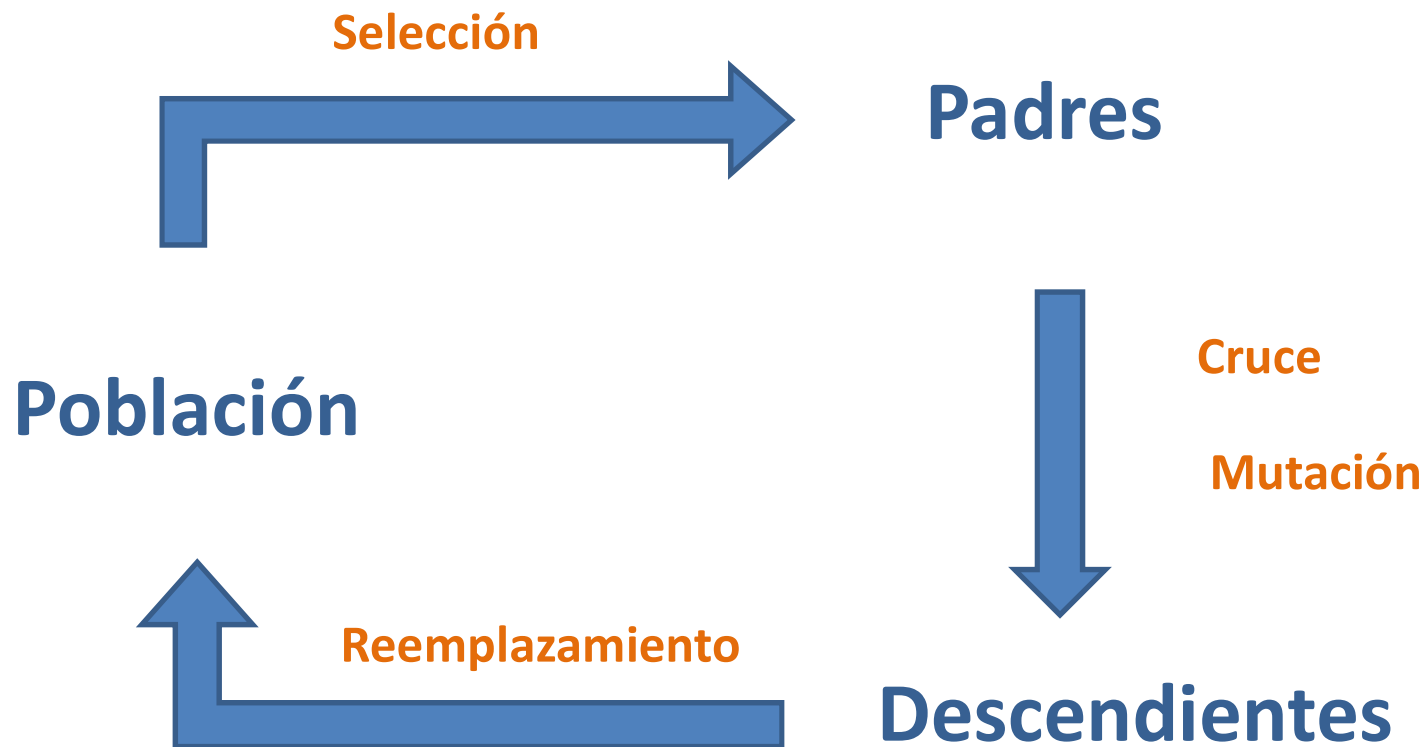
- Selecciona aleatoriamente dos posiciones e intercámbialas (también inserción o subinversión – [ver tema recocido simulado])

7	3	1	8	2	4	6	5
---	---	---	---	---	---	---	---



7	3	6	8	2	4	1	5
---	---	---	---	---	---	---	---

# Ciclo evolutivo. Diseño de un algoritmo genético(IV)



# Estrategia de reemplazamiento

- La estrategia de reemplazamiento determina los individuos que son introducidos o eliminados de la población
- Generacional
  - En cada iteración una nueva población completa reemplaza a la anterior
- Estacionaria (steady-state)
  - Una alternativa a la aproximación generacional (la más frecuente) es actualizar la población individuo a individuo (o en pares) en lugar de a todos de una vez

# Estrategia de reemplazamiento

- Una buena idea en el caso de la aproximación generacional es incluir una estrategia de “elitismo” para no perder la mejor solución encontrada
- **Elitismo:** incluir directamente en la siguiente población el mejor individuo (o un truncamiento de  $n$  mejores) de la anterior sin cruzar ni mutar. Estos individuos se llaman élites

# Criterio de parada

- Si se encuentra el óptimo (requiere conocer cuál es el óptimo a priori, que no suele ser el caso)
- Recursos computacionales limitados. Limitar el número máximo de iteraciones o el tiempo de ejecución
- Después de un tiempo o iteraciones sin mejora

# Ciclo evolutivo. Diseño de un algoritmo genético(V)





# ¡Precaución!

- Como con cualquier algoritmo de optimización aleatoria si es posible utiliza más de una ejecución para sacar conclusiones
  - Utiliza medidas estadísticas (media, mediana...)
  - Haz suficientes replicaciones como para obtener valores significativos
- No ajustes los parámetros del algoritmo en contextos diferentes a los de su uso. No ajustes con casos sencillos si lo utilizarás para resolver casos complejos
- Ten claro si el objetivo es estratégico, táctico u operativo
  - Encontrar una solución buena al menos una vez de varias ejecuciones
  - Encontrar una solución buena en cada ejecución
  - Tiempo de cada ejecución...

## Sobre la diversidad genética


- La falta de diversidad implica convergencia a algo similar a un mejor vecino
- Una alta presión selectiva reduce diversidad rápidamente
- Soluciones:
  - Introducir mecanismos de diversidad
  - Reducir la presión selectiva
  - Ejecutar el algoritmo varias veces

# Exploración vs Explotación

- Exploración: muestrear en regiones desconocidas
  - Si exploras demasiado te acercas a la búsqueda aleatoria -> no hay convergencia, malas soluciones
- Explotación: mejorar el mejor individuo
  - Si intensificas demasiado, te acercas a los algoritmos de búsqueda local que se atascan en óptimos locales

# Algoritmo genéticos

- Basados en una metáfora biológica: la evolución
- Muchas aplicaciones
- Muy populares
- Muy potentes




# El problema del viajante


- 17 ciudades
- Representación: Codificación permutacional
- Población: 61 individuos
- Inicialización: aleatoria
- Selección: torneo aleatorios
- Reemplazamiento: generacional con elitismo (1 élite)
- Cruce: operador OX ( $P_c=0.6$ )
- Mutación: intercambio de dos genes por cromosoma  
 $P_m=0.01$
- Fitness:

$$C(S) = \sum_{i=1}^{n-1} (D[S[i], S[i+1]]) + D[S[n], S[1]]$$

# El problema del viajante




$17! \approx 3.6 \cdot 10^{14}$  posibles soluciones



Solución óptima: 226.64


# El problema del viajante



— Best solution  
- - - Optimal solution

Iteración: 0

Fitness: 403.7




— Best solution  
- - - Optimal solution

Iteración: 25

Fitness: 303.86


# El problema del viajante



—— Best solution  
----- Optimal solution

Iteración: 50

Fitness: 293.6




—— Best solution  
----- Optimal solution

Iteración: 100

Fitness: 256.55




# El problema del viajante




Iteración: 200

Fitness: 231.4



Iteración: 250

Fitness: 226.64



# Resumen

- Aproximación evolutiva (Diversidad, selección y replicación)
- Evolución artificial
- Algoritmo genético
  - Representación
  - Inicialización
  - Fitness
  - Selección
  - Cruce
  - Mutación
  - Reemplazamiento
  - Criterio de parada
- Algunos comentarios adicionales